# Clasificación de cobertura terrestre en la Amazonía usando imágenes satelitales

Cristian Daniel Muñoz Botero Ana Isabel Patiño Osorio Jonathan Andrés Granda Orrego Universidad de Antioquia

## 1. Contexto de Aplicación

La selva amazónica es uno de los ecosistemas más biodiversos del planeta, pero también uno de los más amenazados debido a la deforestación, la expansión agrícola y el cambio climático.

Este proyecto se desarrolla en el marco de una competencia de Kaggle organizada por Planet Labs, una empresa que proporciona imágenes satelitales diarias de la Tierra [1]. El objetivo es utilizar datos satelitales para clasificar automáticamente la cobertura terrestre y las condiciones atmosféricas del Amazonas, asignando etiquetas a distintas clases y situaciones ambientales.

# 2. Objetivo de Machine Learning

El problema es de clasificación multietiqueta: dado un conjunto de imágenes satelitales RGB, el objetivo es predecir una o más etiquetas por imagen, que pueden incluir:

- Cobertura terrestre: agriculture, artisinal\_mine, bare\_ground, blow\_down, conventional\_mine, cultivation, habitation, primary, road, selective\_logging, slash\_burn, water
- Condiciones atmosféricas: blooming, clear, cloudy, haze, partly\_cloudy

Cada imagen puede contener múltiples etiquetas simultáneamente, reflejando la complejidad

del entorno amazónico y la coexistencia de diferentes coberturas y condiciones atmosféricas en una misma escena.

#### 3. Dataset

Fuente: Planet Labs (conjunto de datos proporcionado originalmente en la competencia de Kaggle [1]). Para este trabajo se utiliza un dataset que fue publicado posteriormente como un dataset independiente [2], y que adecua al conjunto de datos original, dado que los archivos originales en formato .torrent resultaban demasiado pesados para la capacidad de cómputo disponible, y los protocolos de descarga generan conflictos en entornos en la nube.

**Tipo de datos:** Imágenes satelitales RGB de  $256 \times 256$  píxeles.

#### Tamaño del dataset:

- 40,479 imágenes en el conjunto de entrenamiento, y 40,669 en el conjunto de prueba (estas últimas sin etiquetas).
- Tamaño en disco: aproximadamente 3 GB comprimido.

Formato: Imágenes en . jpg + archivo . csv con etiquetas.

Distribución de clases: La distribución de clases es desbalanceada. Algunas etiquetas como primary y clear son mucho más comunes que otras como slash\_burn o blow\_down, estas primeras representando alrededor del 80-85 % del conjunto total de imagenes.

## 4. Métricas de Desempeño

# Métrica de ML: F2 Score (promedio macro).

La métrica principal utilizada para evaluar el modelo será el F2 Score, que asigna un mayor peso al recall que a la precisión. Esto resulta útil en contextos donde es más importante detectar todos los casos relevantes (minimizar falsos negativos) que evitar falsos positivos.

$$F_2 = (1 + \beta^2) \cdot \frac{(\operatorname{Precision} \cdot \operatorname{Recall})}{(\beta^2 \cdot \operatorname{Precision}) + \operatorname{Recall}}$$

$$\operatorname{Precision} (\operatorname{precisión}) = \frac{\operatorname{TP}}{\operatorname{TP} + \operatorname{FP}}$$

$$\operatorname{Recall} (\operatorname{sensibilidad}) = \frac{\operatorname{TP}}{\operatorname{TP} + \operatorname{FN}}$$

El promedio macro (macro-averaged F2) se calcula promediando el F2 score de cada clase, tratándolas de forma equitativa pese al desequilibrio de datos.

Métricas de negocio: Dado que el proyecto tiene un enfoque principalmente técnico, podríamos hablar en cuanto a métricas de negocio que son importantes para la aplicación de modelos, esta se relacionan con la eficiencia en el procesamiento de imágenes satélitales. Un modelo más preciso y rápido podría incrementar el Throughput del sistema, es decir, el número de imágenes procesadas automáticamente por unidad de tiempo, permitiendo una detección más temprana de eventos como deforestación, incendios o minería ilegal, por lo que seria bueno contemplar un modelo que tenga menos complejidad computacional en la emisión de predicciones.

Throughput 
$$=\frac{\text{Imágenes procesadas}}{\text{Unidad de tiempo}}$$

#### 5. Estado del arte

Diversos estudios han abordado la clasificación multietiqueta en imágenes satelitales aplicadas al monitoreo ambiental y la cobertura

terrestre. Singh y Shankar (2022) propusieron un enfoque basado en modelos preentrenados y técnicas de *data augmentation*, junto con funciones de pérdida adaptadas al desbalance de clases, logrando mejoras en tareas de clasificación sobre la Amazonía [4].

Por su parte, Ji et al. (2020) introdujeron una arquitectura híbrida que combina redes convolucionales (CNN) con redes recurrentes (LSTM) y mecanismos de atención para capturar dependencias semánticas entre etiquetas, mejorando la detección de clases raras en entornos naturales complejos [5].

Estas metodologías sirven como base conceptual para el presente trabajo, que busca aplicar principios similares de transferencia de aprendizaje y optimización de métricas sensibles al recall, como el F2 Score, en el contexto específico de la clasificación de cobertura terrestre amazónica.

#### 6. Referencias

#### Referencias

- [1] Planet Labs. (2017). Planet: Understanding the Amazon from Space [Competencia de Kaggle]. Recuperado de https://www.kaggle.com/competitions/planet-understanding-the-amazon-from-space/overview
- [2] Rom, N. (2017). Planets Dataset [Conjunto de datos en Kaggle]. Recuperado de https://www.kaggle.com/datasets/nikitarom/planets-dataset/data
- [3] Planet Labs Inc. (2017). Planet imagery and data products. Disponible en https://www.planet.com/
- [4] Singh, A.K. & Shankar, B.U. (2022). Multi-Label Classification on Remote-Sensing Images. arXiv:2201.01971.
- [5] Ji, J., Jing, W., Chen, G., Lin, J., & Song, H. (2020). Multi-Label Remote Sensing Image Classification with Latent Semantic Dependencies. Remote Sensing, 12(7), 1110.